

Credit Risk Modeling on Apache Spark, Kafka and Hadoop

Hệ thống xử lý đầu cuối phân tán trên bộ dữ liệu Home Credit Default Risk

Nguyễn Việt Phương

Mã sinh viên: 24022431

Môn học: Big Data | Giảng viên: Trần Hồng Việt

25/06/2026

github.com/muahahaha55/Big_Data_Final_Exam

- 1 Bài toán và động lực Big Data
- 2 Tổng quan bộ dữ liệu Home Credit
- 3 Kiến trúc hệ thống
- 4 Lựa chọn công nghệ
- 5 Tầng lưu trữ HDFS
- 6 Quy trình ETL đa bảng
- 7 Tối ưu hoá Spark
- 8 Kỹ thuật đặc trưng
- 9 Huấn luyện mô hình GBT
- 10 Phân tích rủi ro Basel II
- 11 Phân tầng rủi ro và Tổn thất Kỳ vọng
- 12 Kịch bản kiểm tra căng thẳng
- 13 Hệ thống streaming Kafka + Spark
- 14 Giám sát mô hình - PSI, KS, JS
- 15 Tuyển chọn đặc trưng Kruskal-Wallis
- 16 Quy trình tái huấn luyện theo drift
- 17 Phân tích khám phá dữ liệu (EDA)
- 18 Hạn chế trung thực và đánh đổi
- 19 Kết luận

Bài toán và Động lực Big Data

Bài toán nghiên cứu

Dự đoán Xác suất Vỡ nợ (PD) từ nhiều nguồn dữ liệu quan hệ, định lượng rủi ro danh mục theo khung Basel II.

- Quy mô: hàng chục triệu KH mỗi ngày
- Đầu vào: 7 bảng quan hệ, 3 mức hạt
- Biến mục tiêu: nhị phân, tỉ lệ vỡ nợ 8.1%

**Nguồn: arXiv:2511.03807, bộ dữ liệu tín dụng công khai (mang tính minh họa).*

Bốn chữ V của Big Data

- **Volume:** ~2.5 GB, 27 triệu hàng trung gian
- **Variety:** 7 bảng, 3 mức hạt
- **Velocity:** đơn vay liên tục $\Rightarrow$ streaming
- **Veracity:** dữ liệu phi dừng, PD biến động ~15% (2015) $\rightarrow$ 23% (2024)*

Tổng quan Bộ dữ liệu Home Credit

Bảng	Số hàng	Cột
application_train	307,511	122
bureau	1,716,428	17
bureau_balance	27,299,925	3
previous_application	1,670,214	37
installments_payments	13,605,401	8
credit_card_balance	3,840,312	23
POS_CASH_balance	10,001,358	8
Tổng cộng	~58.4 triệu	—

Vì sao không dùng Pandas?

- 58.4M hàng không nằm gọn trong bộ nhớ đơn nút (4-8 GB)
- Join 7 bảng ở 3 mức hạt $\Rightarrow$ shuffle phân tán
- Spark: một runtime cho batch + streaming + ML

Phân bố biến mục tiêu

Không vỡ nợ: 282,686 (91.9%)

Vỡ nợ: 24,825 (8.1%)

$\Rightarrow$ Cần cân trọng số lớp khi huấn luyện

Kiến trúc Hệ thống

Đường xử lý theo lô (Batch)

- 1 Đọc 7 CSV từ HDFS
- 2 Gộp bảng con → join về application_train
- 3 Pipeline kỹ thuật đặc trưng (Spark ML)
- 4 Huấn luyện GBT trên Spark MLlib
- 5 Ghi run / đăng ký mô hình → MLflow
- 6 Phân tích rủi ro → báo cáo JSON
- 7 Phát hiện drift → quyết định tái huấn luyện

Đường xử lý thời gian thực (Streaming)

- 1 Producer phát đơn vay JSON → Kafka
- 2 Spark Structured Streaming tiêu thụ
- 3 Chấm điểm cùng module suy luận batch
- 4 Phát kết quả → topic Kafka
- 5 Tổng hợp cửa sổ 1 phút: số đơn, PD TB, EL

Lỗi nghiệp vụ dùng chung

`credit_risk/inference/realtime.py` - `assign_tier()`, `make_decision()`, `expected_loss()`. Bảo đảm không lệch giữa huấn luyện và suy luận ngay từ thiết kế.

Lựa chọn Công nghệ

Tầng	Công nghệ	Lý do lựa chọn
Lưu trữ phân tán Quản lý cụm Tính toán theo lô	HDFS 3.3.6 YARN Apache Spark 3.5 + PySpark	Sao chép cấp khối, I/O phân tán thực sự Bộ lập lịch chuẩn Hadoop, chạy trên cụm Vector hoá, join đa bảng native, một API cho ETL+ML
Học máy Theo dõi thí nghiệm	Spark MLlib (GBT) MLflow 2.9 + SQLite	Huấn luyện phân tán trong Spark, không xuất dữ liệu Đăng ký mô hình gọn nhẹ, phù hợp khoá luận
Hàng đợi tin nhắn Xử lý streaming	Apache Kafka 3.5 Spark Structured Streaming	Hàng đợi có thể phát lại, chuẩn theo sự kiện Dùng lại code path Spark, sink checkpoint exactly-once
Điều phối Ngôn ngữ	Make + Docker Compose Python 3.12	Môi trường dev tái lập, production: Airflow / Argo Hỗ trợ đầy đủ PySpark, scipy, mlflow

Mỗi tầng - một công nghệ - một lý do duy nhất. Không có công nghệ nào được thêm chỉ để biểu diễn.

Tầng Lưu trữ HDFS

Ba lợi ích cụ thể của HDFS

- Sao chép cấp khối (hệ số 3) → tăng độ bền dữ liệu không cần code thêm
- Spark đọc song song theo định vị khối → I/O phân tán thực sự
- Parquet phân vùng trên HDFS → partition pruning ở bước sau

Cấu hình `conf/base/config.yaml`

```
hdfs:  
  enabled: true  
  base_path:  
    hdfs://.../credit_risk  
  raw_path: hdfs://.../raw  
  processed_path: hdfs://.../processed  
  results_path: hdfs://.../results
```

Quy trình ETL Đa bảng

Mẫu gộp dữ liệu (PySpark)

```
df_child.groupBy("SK_ID_CURR")  
  .agg(F.count("*"),  
       F.avg("AMT_OVERDUE"),  
       F.sum("AMT_DEBT"),  
       F.max("DAYS_LATE"))
```

Kết quả join bureau:

1,716,428 hàng → **307,511 × 126 cột** (+4 đặc trưng)

Tất cả join đều là LEFT JOIN trên SK_ID_CURR để giữ lại khách hàng không có lịch sử.

Bảng con	Chiến lược gộp	ĐT
bureau	count, active/closed, mean overdue	4
previous_app	count, approved/refused, mean amt	8
installments	mean/max DPD, count late	6
credit_card	mean balance/util, sum DPD	6
pos_cash	count, max DPD, late count	5

Tối ưu hoá Spark

Bốn kỹ thuật tối ưu

- **AQE** bật sẵn → tự gộp phân vùng shuffle, xử lý skew
- **Kryo serializer** → giảm ~50% thời gian serialize
- **PyArrow** → chuyển Spark ↔ Pandas nhanh khi materialise
- **Snappy/Parquet** → giảm I/O, vẫn splittable

Hiệu chỉnh bộ nhớ VM 3.8 GB

```
.config("spark.driver.memory", "2g")  
.config("spark.executor.memory", "1g")  
+ 2 GB swap để OS không OOM-kill Spark khi join nặng.
```

Bài học: thích nghi với môi trường thi cử, không phải khuyến nghị production.

Sáu đặc trưng nghiệp vụ

- $DEBT_INCOME = AMT_CREDIT / AMT_INCOME$
- $ANNUITY_INCOME = (AMT_ANNUITY \times 12) / AMT_INCOME$
- $CREDIT_GOODS = AMT_CREDIT / AMT_GOODS_PRICE$
- $CREDIT_TERM = AMT_CREDIT / AMT_ANNUITY$
- $EMPLOYMENT_RATIO = DAYS_EMPLOYED / DAYS_BIRTH$
- $EXT_SOURCE_MEAN = \text{mean}(EXT_SOURCE_1, 2, 3)$

Spark ML Pipeline

- 1 Imputer - median/mode
- 2 StringIndexer
- 3 OneHotEncoder
- 4 VectorAssembler
- 5 StandardScaler

Pipeline fit trên train, áp dụng cho val/test/streaming $\Rightarrow$ nhất quán huấn luyện - suy luận.

Huấn luyện Mô hình GBT

Chỉ số	Giá trị	Ý nghĩa
ROC-AUC	0.7663	phân tách mạnh
PR-AUC	0.2461	phù hợp lớp 8%
KS	0.4016	vượt ngưỡng 0.30
Accuracy	0.9178	lệch do imbalance
F1 (weighted)	0.8830	—
Precision	0.8839	—
Recall	0.9178	—
PD trung bình	8.29%	vs thực tế 8.2%

Nguồn: MLflow credit_risk_platform / gbt_baseline.

Vì sao chọn GBT?

- MLib có sẵn $\Rightarrow$ không xuất dữ liệu
- Huấn luyện phân tán trên nhiều executor
- Bất tương tác phi tuyến trong tín dụng
- Hỗ trợ cân trọng số lớp

KS = 0.4016 vượt ngưỡng 0.30 mà giới ngân hàng chấp nhận cho scorecard production.

Phân tích Rủi ro Basel II

Chỉ số danh mục	Giá trị
Tổng khách hàng chấm điểm	45,859
Tổng EAD	27,407.37 M
Tổng Tổn thất Kỳ vọng (EL)	950.72 M
Tỉ lệ EL trên danh mục	3.47%
PD trung bình	8.29%
LGD trung bình	45.0% (Basel II FIRB)
Tỉ lệ vỡ nợ thực tế	8.2%

Vốn kinh tế (Basel II)

Đại lượng	Triệu
Tổn thất Kỳ vọng (EL)	950.72
Tổn thất Bất thường (UL)	2,852.17
Vốn kinh tế	4,278.25

Hiệu chỉnh

PD trung bình mô hình **8.29%** $\approx$ tỉ lệ vỡ nợ thực tế **8.2%**, lệch dưới 0.1 điểm phần trăm.

Phân tầng Rủi ro Danh mục

Tầng rủi ro	Số KH	% DM	EAD (M)	EL (M)	EL rate	PD TB
Thấp	34,822	75.93%	21,629.76	455.88	2.11%	4.78%
Trung bình	7,465	16.28%	3,987.75	247.16	6.20%	13.82%
Cao	2,630	5.73%	1,325.93	153.26	11.56%	25.69%
Rất cao	942	2.05%	463.93	94.42	20.35%	45.49%

Nhận xét chính

- Đuôi mỏng (2.05%) nhưng tỉ lệ EL gấp **9.6×** tầng Thấp (20.35% vs 2.11%)
- Phân tầng thực sự phân biệt, không phân bố đều
- Quy tắc Basel: đuôi tiêu thụ hầu hết vốn kinh tế dù chiếm <5% danh mục

Công thức tính EL

$$EL = PD \times LGD \times EAD$$

PD: đầu ra mô hình GBT

LGD: 0.45 cố định (Basel II FIRB)

EAD: AMT_CREDIT của khách hàng

Kiểm tra Căng thẳng Macro

Kịch bản	PD×	LGD×	EL (M)	EL rate	Vốn (M)	KH rủi ro cao
Cơ sở (baseline)	1.0	1.0	950.72	3.47%	2,852.17	3,572
Suy thoái nhẹ	1.5	1.1	1,567.68	5.72%	4,703.05	7,255
Khủng hoảng 2008	2.5	1.3	3,047.41	11.12%	9,142.22	14,799
Thiên nga đen	4.0	1.5	5,376.49	19.62%	16,129.48	24,623

Hai con số đáng nhớ

- Thiên nga đen: EL danh mục tăng **5.66×** (từ 950.72 M → 5,376.49 M - mất thêm 4,425.77 M)
- Số KH rủi ro cao tăng **~7×** (từ 3,572 → 24,623)
- *Ý nghĩa:* danh mục bán lẻ suy thoái nhanh khi vĩ mô xấu. Ước lượng PD gốc chưa đủ nếu thiếu tăng stress test.

Hệ thống Streaming Kafka + Spark

Luồng xử lý

Producer (JSON) → loan-applications → Spark Streaming (chấm điểm + gộp 1 phút) → scoring-results → Consumer / dashboard.

acks=all, gzip, watermark 2 phút

Cam kết exactly-once

- Producer: acks=all, replication
- Spark: checkpoint offset
- Sink: ghi topic idempotent

Cửa sổ 1 phút (xác minh)

Tổng đơn vay	30
Duyệt (APPROVE)	28
Xem xét (REVIEW)	2
Từ chối (REJECT)	0
PD trung bình	0.0927
Tổng EL	1.56 M
Khoản vay trung bình	1.15 M

Tối ưu Kafka: batch.size=16KB, linger.ms=10, gzip giảm 60-70% băng thông.

Giám sát Mô hình - PSI, KS, JS

PSI + KS cho đặc trưng số

- PSI: binning theo phân vị phân phối tham chiếu
- Ngưỡng Siddiqi: <0.10 ổn định; $0.10-0.25$ theo dõi; ≥ 0.25 tái huấn luyện
- KS hai mẫu: kiểm định phi tham số

Jensen-Shannon cho hạng mục

JS đối xứng, chặn trong $[0,1]$, hiểu được như khoảng cách. Phát hiện thêm hạng mục mới — chỉ báo sớm taxonomy upstream thay đổi.

Nguồn: *arXiv:2511.03807*.

Đầu ra JS divergence (xác minh)

```
NAME_CONTRACT_TYPE JS=0.0019 [none]
CODE_GENDER JS=0.0044 [none]
NAME_FAMILY_STATUS JS=0.0047 [none] new=['Unknown'] (!)
WALLSMATERIAL_MODE JS=0.0107 [none]
```

Phát hiện: tập test có hạng mục mới 'Unknown' ở NAME_FAMILY_STATUS — drift mà PSI số không phát hiện.

Tuyển chọn Đặc trưng Kruskal-Wallis

Vì sao chọn Kruskal-Wallis?

- Không giả định chuẩn / đồng phương sai — phù hợp đặc trưng tài chính lệch
- Xếp hạng rank-sum giữa TARGET=0 và TARGET=1
- Nguồn: Ashofteh & Bravo (2021); Discover AI 2025

Đặc trưng	H	#
EXT_SOURCE_3	4,672.97	1
EXT_SOURCE_2	4,649.61	2
DAYS_BIRTH	1,371.48	3
DAYS_EMPLOYED	144.83	4
AMT_INCOME_TOTAL	72.98	5
AMT_CREDIT	70.51	6

Tất cả $p\text{-value} < 1e-16$. EXT_SOURCE đứng đầu cả ở correlation (Cell 9 EDA) lẫn Kruskal-Wallis — xác nhận chéo trên hai phương pháp.

Quy trình Tái huấn luyện theo Trôi dữ liệu

Điều kiện	Hành động	Mức độ
Bất kỳ đặc trưng nào có $PSI \geq 0.25$	RETRAIN_IMMEDIATE	cao
Có ≥ 3 đặc trưng với $PSI \in [0.10, 0.25)$	RETRAIN_SCHEDULED	trung bình
Có 1-2 đặc trưng với $PSI \in [0.10, 0.25)$	CONTINUE_MONITORING (watchlist)	thấp
Tất cả $PSI < 0.10$	CONTINUE_MONITORING	không

Kết quả chạy thực tế trên VM

✓ **RETRAINING DECISION:**
CONTINUE_MONITORING
Severity: NONE
Reason: No drift detected.

Lợi ích

Tránh tái huấn luyện không cần thiết khi dữ liệu ổn định, kích hoạt nhanh khi thực sự có thay đổi phân phối.
Lưu vào `data/08_reporting/retraining_decision.json`.

Phân tích Khám phá Dữ liệu (EDA)

Cấu trúc 13 cell notebook

- Cell 5: Tổng quan 7 bảng – hàng/cột
- Cell 6: Phân bố TARGET – 92/8 imbalance
- Cell 7: 20 cột thiếu nhiều nhất
- Cell 8: Phân phối 4 DT số theo TARGET
- Cell 9: Ma trận tương quan với TARGET
- Cell 10: Tỷ lệ vỡ nợ theo hạng mục
- Cell 11: Demo join application + bureau
- Cell 12: Kruskal-Wallis ranking

Phát hiện chính

- Imbalance 91.9% / 8.1%
- EXT_SOURCE_1/2/3 mạnh nhất, xác nhận chéo bởi correlation và Kruskal-Wallis
- Tỷ lệ vỡ nợ tăng theo NAME_EDUCATION: Academic degree (1.8%) → Lower secondary (10.9%)
- Cash loans vỡ nợ **1.6**× so với revolving
- Cột thiếu tập trung ở housing/building (60–70%)

Hạn chế Trung thực và Đánh đổi

Ràng buộc kỹ thuật

- Triển khai single-node pseudo-distributed, chưa lên cụm thật
- Chưa benchmark Spark optimisation (AQE, Kryo chỉ tuyên bố)
- Spark MLlib GBT thua LightGBM/XGBoost 1-2 pp ROC-AUC — đánh đổi có chủ ý
- Drift offline (train vs test), chưa rolling window

Ràng buộc nghiên cứu

- Chưa ablation study đo đóng góp đặc trưng đa bảng
- Chỉ một lần chạy huấn luyện — chưa cross-validation
- Stress test dùng nhân tử cố định, chưa có satellite model vĩ mô
- Chưa kiểm định ý nghĩa thống kê khi so sánh các ngưỡng drift

Liệt kê tường minh là có chủ đích. Cả bốn khoảng trống đều ánh xạ vào lộ trình mở rộng đã ghi trong báo cáo (mục 11).

Kết luận

1. Hệ thống đầu cuối

Hệ thống xử lý phân tán đầu cuối (Spark + Kafka + HDFS + MLflow) trên 307,511 khách hàng và 7 bảng quan hệ. Đường streaming dùng lại nguyên xi module suy luận của batch $\Rightarrow$ tránh lệch huấn luyện – triển khai.

2. Mô hình GBT đạt chuẩn production

ROC-AUC = **0.7663** và KS = **0.4016** (vượt ngưỡng 0.30), hiệu chỉnh tốt với PD trung bình 8.29% $\approx$ tỉ lệ vỡ nợ thực tế 8.2%.
Phân tích Basel II: EL danh mục 950.72 M, vốn kinh tế 4,278.25 M.

3. Giám sát có cơ sở học thuật

Tầng giám sát có cơ sở (PSI + KS + Jensen-Shannon + Kruskal-Wallis) và quy trình tái huấn luyện theo drift — không chỉ tuyên bố, mà đã chạy thực tế và lưu kết quả JSON (data/08_reporting/).

Tinh thần trung thực kỹ thuật: mọi con số trên slide đều đến từ một lần chạy thực tế trên VM. Những điều chưa đo được (vd. Δ AUC ablation) đều được nêu rõ là chưa đo.

Demo Sản phẩm

Pipeline batch

```
$ source .venv/bin/activate
$ start-dfs.sh && start-yarn.sh
$ mlflow server --host 0.0.0.0
  --port 5000 &
$ python pipelines/etl_pipeline.py
$ python pipelines/training_pipeline.py
$ python pipelines/risk_pipeline.py
$ python pipelines/monitoring_pipeline.py
$ python pipelines/
  feature_selection_pipeline.py
$ python pipelines/
  categorical_drift_pipeline.py
```

Pipeline streaming

```
$ zookeeper-server-start.sh &
$ kafka-server-start.sh &
$ kafka-topics.sh --create \
  --topic loan-applications ...
$ kafka-topics.sh --create \
  --topic scoring-results ...
# Terminal 1 - scorer
$ python streaming/spark_streaming.py \
  --output console --trigger 10
# Terminal 2 - producer
$ python streaming/kafka_producer.py \
  --mode random --rate 3 --total 30
```

Cảm ơn thầy và các bạn

Rất mong nhận được góp ý

Nguyễn Việt Phương

Mã sinh viên: 24022431 | Môn học: Big Data

github.com/muahahaha55/Big_Data_Final_Exam